

Binarização Híbrida de Imagens de Documentos Históricos Degradados: Uma Releitura Adaptada

Vitor Guedes Frade - 221017130
Ryan Reis Fontenele - 211036132
Mateus Elias de Macedo - 222011561
Departamento de Ciências da Computação
Universidade
Brasília, Brasil
vitorguedesfrade@gmail.com
ryanreisfonte@gmail.com
mateus.emacedo@gmail.com

?abstractname? —This paper presents a reinterpretation and adaptation of a hybrid system for binarizing degraded historical document images. Based on techniques established in the literature, the implemented method integrates pre-processing, dynamic global binarization, adaptive local binarization, and morphological post-processing. Adaptations were made to the original method to improve results, substituting some approaches with optimized implementations, such as Multi-Otsu and Hit-Miss morphology. Parameter adjustments diverging from the base article were empirically chosen to better suit the specific degradation profiles of our test set. The results demonstrate the algorithm's efficacy in preserving writing strokes in low-contrast regions and mitigating background noise, smear, and unwanted artifacts.

Index Terms—Image Processing, Hybrid Binarization, Historical Documents, Otsu, Nick's Method, CLAHE, Mathematical Morphology.

I. INTRODUÇÃO

A binarização de imagens de documentos é uma etapa importante e crítica em muitos sistemas de análise e reconhecimento de documentos, devido a sua importância para transcrever imagens em níveis de cinza em representações binárias que facilitem tarefas de sistemas de reconhecimento óptico de caracteres (OCR), indexação e preservação digital de documentos. Em documentos históricos, esse processamento é dificultado por degradações típicas: iluminação não uniforme, manchas, vazamento de tinta, variações de contraste e caracteres parcialmente apagados; o que compromete a legibilidade de algoritmos de reconhecimento, tanto quanto compromete a segmentação do texto. Esta binarização é salutar, devido sua influência sobre todo o processo de segmentação - influenciando a extração de características, leitura e preservação - erros que permaneçam na binarização se propagam na segmentação.

Na literatura de reconhecimento óptico de caracteres, existem abordagens consideradas globais e propostas híbridas que combinam pré-processamento, limiarização e pós-processamento para lidar com regiões da imagem com fatores que dificultariam o reconhecimento óptico pelos algoritmos. Observe-se que o uso de uma abordagem híbrida favorece satisfazer determinados parâmetros que satisfaçam maior le-

gibilidade de acordo com determinados parâmetros, a citar, o contraste.

O presente trabalho consiste na reprodução da metodologia proposta por Boudraa et al. (2019) [1], que sugere um sistema de binarização em múltiplas fases (pré-processamento, binarização híbrida seguida de pós-processamento). Contudo, para fins de melhoria de desempenho e adequação das ferramentas disponíveis, foram implementadas modificações estratégicas na lógica de limiarização global e nas operações de pós-processamento, buscando resultados superiores no tratamento de ruídos e artefatos específicos das imagens utilizadas no conjunto de testes.

II. METODOLOGIA E ADAPTAÇÕES

O desenvolvimento foi conduzido em ambiente Python. O algoritmo foi estruturado nas seguintes etapas, com divergências metodológicas e de parametrização em relação ao artigo base justificadas a seguir:

A. Pré-Processamento e Análise de Contraste

Para tratar imagens com iluminação deficiente, implementou-se uma etapa de análise de contraste local de Michelson (núcleo 3×3). A média global desse mapa de contraste dita a aplicação do CLAHE. O limite de aplicação (contraste médio $< 0,02$) foi mantido como um estimador robusto para imagens altamente desbotadas.

B. Limiarização Global Dinâmica (Divergência TSMO vs. Multi-Otsu)

Diferentemente do método TSMO original sugerido pela literatura base, esta releitura adota o algoritmo Multi-Otsu (com 3 classes) em conjunto com o Otsu padrão. A decisão sobre qual limiar utilizar baseia-se diretamente no valor do contraste local médio calculado na etapa anterior, utilizando três faixas de restrição empíricas ($T_{01} = 0,03$, $T_{02} = 0,04$ e $T_{03} = 0,085$).

Esses parâmetros foram ajustados empiricamente para a nossa base de testes, pois os intervalos originais sugeridos no artigo base geravam perdas acentuadas na continuidade

dos traços em imagens com contraste marginal. A lógica de decisão estruturada ocorre sob as seguintes faixas:

- **Contraste Extremo Baixo** ($\leq T_{01}$): Utiliza o limiar superior do Multi-Otsu.
- **Contraste Muito Baixo** ($\leq T_{02}$): Analisa a densidade de pixels na faixa intermediária e a distância entre os limiares. Caso atenda às condições restritivas, adota-se o limiar superior do Multi-Otsu; caso contrário, o Otsu clássico.
- **Contraste Moderado** ($\leq T_{03}$): Aplica a limiarização clássica de Otsu.
- **Contraste Alto** ($> T_{03}$): Utiliza o limiar inferior do Multi-Otsu para evitar ruídos de fundo.

C. Limiarização Local Adaptativa de Nick

Para tratar as áreas onde a binarização global falha (textos desbotados e manchas), implementou-se o método adaptativo de Nick:

$$T(x, y) = m + k_{nick} \sqrt{\frac{\sum (p_i^2) - m^2}{N}} \quad (1)$$

Justificativa do Parâmetro: O artigo base e a literatura frequentemente sugerem valores de k_{nick} entre $-0,1$ e $-0,2$. Neste trabalho, optou-se pelo valor divergente $k_{nick} = -0,05$ e janela $ws = 7$. Um valor absoluto menor de k torna o limiar menos agressivo. Isso foi intencional: visou-se preservar mais informações dos traços do texto em áreas severamente manchadas, assumindo o risco de manter algum ruído residual, o qual é agressivamente tratado e eliminado na nossa etapa otimizada de pós-processamento (Hit-Miss).

D. Detecção de Manchas e Mesclagem Híbrida

O algoritmo subdivide a imagem binarizada globalmente em blocos não sobrepostos de 7×7 . Se a fração de pixels pretos excede $\mu + k_{smear}\sigma$, a região é classificada como mancha. O valor escolhido de $k_{smear} = 0,001$ difere do habitual estatístico (que seria mais conservador) para aumentar a sensibilidade da detecção de manchas (smears), forçando o algoritmo a usar o método de Nick em praticamente qualquer região suspeita de acúmulo de tinta.

E. Pós-processamento Morfológico Hit-Miss e Filtragem de Componentes

O artigo base sugere alguns passos vagos para o pós processamento da imagem, mas não apresenta muitos detalhes dos métodos específicos utilizados para implementar as soluções. Nessa releitura, foram utilizadas operações morfológicas via transformada *Hit-Miss* para remover buracos e pixels isolados, assim como corrigir leves artefatos de concavidade e convexidade produzidos pela binarização, aliada a uma rigorosa filtragem de componentes conexos.

Após isso, foi realizada a detecção dos componentes conexos e encontrado suas áreas, como feito no trabalho original, mas algumas mudanças tiveram de ser feitas para resultados mais coerentes serem obtidos. As etapas exatas de toda a pipeline de pós processamento são registrados abaixo:

- 1) **Gaps e Dots (Pontos isolados e Buracos):** Remoção de falsos pixels de *foreground* e preenchimento de buracos de 1 pixel no texto utilizando matrizes específicas da transformada *Hit-Miss*.
- 2) **Filtragem por Componentes Conexos:** O algoritmo utilizado analisa todas as componentes e remove sumariamente aquelas com áreas inferiores a um limite estatístico restritivo $(\lambda \cdot \mu)/\sigma$, onde μ é a média do tamanho das áreas dos componentes, σ seu desvio padrão e $\lambda = 15$ uma constante empírica. No trabalho original, as equações propostas implicavam na remoção dos componentes de área maior que a expressão $(\lambda \cdot \mu)/\sigma$, porém a implementação através dessa lógica resultava na remoção quase inteira do texto em especial em casos de escrita cursiva, nos quais palavras inteiras formam um componente único. Devido à escassez de detalhes dessa etapa no artigo e à ausência de um repositório acessível, não se pode confirmar se essa lógica é intencional, ou resultado de um erro de transcrição, mas sua inversão resultou em notável aprimoramento da imagem final e, portanto, escolheu-se eliminar os componentes menores.
- 3) **Convexidades e Concavidades:** Por fim, foram criados bancos de kernels que representavam concavidades e convexidades de um pixel em cada direção (Cima, Baixo, Esquerda, Direita). Essas matrizes foram utilizadas pela operação *Hit-Miss* suavizar o contorno dos caracteres e remover artefatos gerados pela binarização.

F. Métodos de Avaliação

Para avaliar o desempenho do algoritmo em sua binarização, foram utilizadas quatro métricas principais, sendo feitas com comparação *aground truths* disponibilizadas junto às bases de dados utilizadas. As métricas utilizadas foram:

- 1) **F-Measure:** Uma medição padrão da acurácia de modelos representada pela fórmula:

$$FM = \frac{2 * Recall * Precision}{Recall + Precision}$$

onde $Recall = \frac{TP}{TP+FN}$ e $Precision = \frac{TP}{TP+FP}$, sendo TP, FN e FP respectivamente os valores de verdadeiro positivo, falso negativo e falso positivo do modelo.

- 2) **pseudo F-Measure:** Uma medida introduzida em [3] e baseada o *F-Measure*, mas que substitui Recall por pseudo-Recall R_{ps} e Precision por pseudo-Precision P_{ps} . Essas medidas são baseadas na distância ao contorno dos caracteres da *ground truth* e, no caso do pseudo-Recall, também é normalizado de acordo com a espessura do traço.
- 3) **Peak Signal to Noise Ratio (PSNR):** Uma medida que determina a semelhança entre duas imagens, sendo I e I' duas imagens de dimensão $M \times N$ e C a diferença entre pixels do *foreground* e *background*, ela é definida como:

$$PSNR = 10 \log \left(\frac{C^2}{MSE} \right)$$

onde

$$MSE = \frac{\sum_{x=1}^M \sum_{y=1}^n (I(x, y) - I'(x, y))^2}{MN}$$

- 4) **Distance Reciprocal Distortion Metric (DRD)**: Uma medida baseada na visão humana que mede a distorção visual em documentos, como usada em [4]. A distorção de todos os S flipped pixels é definida por:

$$DRD = \frac{\sum_{k=1}^S DRD_k}{NUBN}$$

Nessa expressão, $NUBN$ é o número de blocos 8×8 não uniformes na imagem e DRD_k é a distorção do k -ésimo pixel virado, calculado através da matriz normalizada 5×5 de pesos W_{NM} , definida em [4].

III. RESULTADOS E DISCUSSÃO

O método proposto foi testado na base de imagens H-DIBCO de 2014 [2], composta por 10 imagens de documentos manuscritos, suas *ground truths* e executáveis utilizados para avaliar o desempenho do algoritmo testado através das métricas previamente apresentadas.

O cálculo de contraste local aliado à decisão condicional entre Otsu e Multi-Otsu mostrou-se computacionalmente mais leve e eficiente que o TSMO original para as imagens do conjunto de dados.

A Figura 5 ilustra perfeitamente a necessidade da binarização híbrida e o papel crucial da binarização de Nick nas manchas (smear). Na binarização puramente global (Fig. 5b), grandes áreas de acúmulo de tinta ou variação de iluminação colapsam em manchas densas, ocultando completamente o texto. Ao identificar essas regiões (densidade $> \mu + k_{smear}\sigma$) e aplicar localmente a fórmula de Nick com nosso $k_{nick} = -0,05$ otimizado (Fig. 5c), o texto é resgatado do fundo escuro. Por fim, o pós-processamento Hit-Miss (Fig. 5d) elimina os resíduos pontuais e preserva a integridade estrutural da escrita.

Caso o algoritmo fosse executado com os parâmetros sugeridos pelo artigo base (por exemplo, valores de k_{nick} mais negativos e janelas maiores), notaríamos uma erosão excessiva dos caracteres resgatados nas áreas de mancha. A nossa parametrização compensa isso balanceando um k_{nick} tolerante com uma limpeza morfológica posterior rigorosa. As imagens geradas pelo código permitem a validação visual dessas assunções perante a literatura base.

IV. CONCLUSÃO

A partir releitura do artigo, o intuito inicial foi obter resultados semelhantes aos apresentados Boudraa et al. (2019) [1], ao qual inicialmente seguimos escrupulosamente sua metodologia. Ao realizarmos os testes com o banco de imagens citado (dataset), observou-se que alguns parâmetros e, principalmente a etapa de pós-processamento, exigiam ajustes para melhor adequação às características específicas das imagens avaliadas. Diante disto, foram investigados parâmetros e técnicas que favorecessem a legibilidade do texto e a preservação das




Figura 1. *
(a) Imagem Original




Figura 2. *
(b) Binarização Global




Figura 3. *
(c) Binarização de Nick




Figura 4. *
(d) Final (Pós-processada)

Figura 5. Comparativo das etapas na imagem H05. A binarização global (b) deixa manchas opacas devido à degradação. A aplicação da limiarização de Nick (c) nestas regiões recupera o texto, sendo o ruído residual limpo no pós-processamento (d).

informações relevantes para um futuro reconhecimento óptico de caracteres (OCR), processo este no qual se verificou que o algoritmo de Nick, apesar de eficiente na delimitação de traços de contorno, apresentou limitações na região do interior dos contornos, sobretudo em regiões de escrita mais espessa. Apesar deste fator, o método global mostrou bom desempenho e, em situações com manchas e desgastes acentuados, o método adaptativo de Nick desempenhou nestas situações potencial satisfatório, apesar de demandar correções.

A adaptação consciente dos parâmetros, sobretudo no limiar do algoritmo de Nick e no critério estatístico de detecção de manchas, somada à substituição do pós-processamento original por operações Hit-Miss, demonstrou-se como solução eficaz para os testes realizados. Os resultados obtidos indicam recuperação satisfatória de informações em documentos gravemente degradados, evidências da validade técnica das adaptações realizadas.

Aos trabalhos futuros, recomenda-se a reimplantação do algoritmo de Nick, de modo a sanar a preservação do interior dos traços em regiões com escrita mais espessa, além da exploração de técnicas de aprendizado profundo para aprimorar a detecção de manchas e o processo de binarização adaptativa.

REFERÊNCIAS

- [1] O. Boudraa, W. K. Hidouci, and D. Michelucci, "Degraded Historical Documents Images Binarization Using a Combination of Enhanced Techniques," *arXiv preprint arXiv:1901.09425*, 2019.
- [2] K. Ntirogiannis, B. Gatos and I. Pratikakis, "ICFHR2014 Competition on Handwritten Document Image Binarization (H-DIBCO 2014)," 2014 14th International Conference on Frontiers in Handwriting Recognition, Hersonissos, Greece, 2014, pp. 809-813, doi: 10.1109/ICFHR.2014.141.
- [3] Chris Tensmeyer and Tony Martinez. 2020. Historical Document Image Binarization: A Review. *SN Comput. Sci.* 1, 3 (May 2020). <https://doi.org/10.1007/s42979-020-00176-1>

- [4] Lu, Haiping & Kot, A.C. & Shi, Y.Q.. (2004). Distance-Reciprocal Distortion Measure for Binary Document Images. *IEEE Signal Processing Letters*. 11. 228-231. 10.1109/LSP.2003.821748.